

Possíveis Melhorias na DAG

- Analise o Código de Nossa DAG
- Pense o que poderia dar errado
- ...



Casos

- Interrupção durante a carga no Snowflake
 - Pode levar a uma carga incompleta dos dados
 - Solução: controle de transação: ou tudo ou nada.
- Execução Simultânea da Dag:
 - Pode levar a duplicidade de dados, uma vez que uma instância já tem o ID máximo, outra instância pode pegar o mesmo ID, ou no intervalo, e iniciar a inserção
 - Solução: max_active_runs=1 na Dag garante a execução serializada
 - Solução: uso de merge (UPSERT)



Casos

- Falhas de Conexões
 - A conexão com o banco de dados pode falhar
 - Solução: implementar novas tentativas com retries e retry_delay
- Problemas de Performance
 - Buscar registros cujos ID > max_id pode se tornar ineficiente. Abordagens usando timestamp podem melhorar a performance
 - Obs: Alternativas são discutidas na última seção do curso.



Qualidade dos Dados

- Testes de Qualidade e Conformidade dos Dados
 - Devem ser feitos, por mais robusto que seja o seu Pipeline
 - Com Python: pytest
 - Uma abordagem interessante é fazer após a carga (SQL)
 - Vamos ver exemplos no dbt

